

Nutzung von generativer KI am Weizenbaum- Institut

Richtlinie

Impressum

Weizenbaum-Institut e.V.

Hardenbergstrasse 32

10623 Berlin

info@weizenbaum-institut.de // weizenbaum-institut.de

Version:	1
Datum der Version:	13.01.2025
Autor:innen:	Jochen Knaus, Sascha Friesike, Ricarda Opitz, Jan Hase, Dietmar Kammerer, Claudia Oellers
Beteiligte Forschungsgruppen / Bereiche:	Forschungsmanagement, Vorstand
Beschlossen durch:	Direktorium
Status:	Beschlossen

Änderungshistorie

Datum	Version	Erstellt durch	Beschreibung der Änderungen
13.01.2025	1	Jochen Knaus, Sascha Friesike, Ricarda Opitz, Jan Hase, Dietmar Kammerer, Claudia Oellers	/

Dauerhafte Verfügbarkeit: DOI [10.5281/zenodo.14844475](https://doi.org/10.5281/zenodo.14844475)



Die Richtlinie ist lizenziert unter Creative Commons CC-BY 4.0 Attribution (<https://creativecommons.org/licenses/by/4.0/>)

Inhalt

Richtlinie	3
Einleitung.....	3
Begrifflichkeit.....	3
Geltungsbereich	3
Risiken der Nutzung generativer KI.....	4
Ausschluss der Nutzung	4
Verantwortlichkeit	5
Prinzipien der Nutzung von generativer KI.....	5
Gültigkeit	5
Appendix.....	6

Richtlinie

Einleitung

Der Einsatz von Werkzeugen der generativen Künstlichen Intelligenz (KI) verändert Arbeits- und Wissenschaftsprozesse. Das Weizenbaum-Institut e. V. (WI) möchte gemäß seinem Leitbild eine konstruktiv-kritische Auseinandersetzung mit den Möglichkeiten von KI ermöglichen, die sowohl praktische und rechtliche Aspekte berücksichtigt, als auch den technischen Fortschritt mit einer ethisch vertretbaren und nachhaltigen Nutzung in Einklang bringt.

Der Einsatz von KI-Werkzeugen am WI soll den wissenschaftlichen Prozess auf vielfältige Weise unterstützen und Routinetätigkeiten in Forschung und Verwaltung vereinfachen.

Mit der Richtlinie werden der Kodex zur guten wissenschaftlichen Praxis am Weizenbaum-Institut und die Leitlinie zum Umgang mit Forschungsdaten ergänzt.

Diese Richtlinie wird unter starker Einbeziehung der Mitarbeitenden und der Nutzungserfahrungen weiter überarbeitet und präzisiert.

Praktische und konkrete Anwendungshinweise und Anleitungen ergänzen die Richtlinie. Es werden Einschluss- und Ausschlusslisten veröffentlicht.

Begrifflichkeit

Systeme, die im Folgenden als „generative KI“ bezeichnet werden, sind in der Lage, Inhalte, seien es Bilder, Töne oder Texte, anhand von Vorgaben neu zu erstellen oder grundlegend umzugestalten. Am WI werden Werkzeuge mit generativer KI in verschiedenen Formen eingesetzt, von Web Services über Code und technische APIs bis hin zur Integration in Programme wie Office.

Werkzeuge, die zwar auf ähnlichen Methoden basieren, aber ausschließlich formale Kriterien prüfen oder anpassen, sind auch Gegenstand dieser Richtlinie. Beispiele sind Übersetzungs- und Transkriptionsdienste.

Geltungsbereich

Diese Richtlinie richtet sich an alle Mitarbeiter:innen des WI sowie an externe Wissenschaftler:innen, sofern ihre Tätigkeit in Projekten des WI stattfindet oder direkt mit dem Institut assoziiert ist.

Darüber hinaus sind immer projektspezifische Vorgaben, Auflagen der jeweiligen Zuwendungsgeber, der Verlage sowie kooperierender Einrichtungen zu beachten.

Die Richtlinie umfasst alle kommerziellen und nicht-kommerziellen Dienste und Modelle für generative KI.

Die Nutzung von privaten Accounts und Lizenzen bei Diensten der generativen KI für dienstliche Zwecke ist nicht gestattet¹. Bei besonderem Bedarf ist die/der KI-Beauftragte ansprechbar.

Die Richtlinie berücksichtigt nicht die studentische Lehre und Aspekte des Studiums.

Risiken der Nutzung generativer KI

Den meisten von WI-Mitarbeiter:innen und Wissenschaftler:innen nutzbaren Diensten der generativen KI ist gemeinsam, dass die eigentliche Datenverarbeitung außerhalb der technischen Infrastruktur des Instituts stattfindet. Das bedeutet, dass die Eingaben z. B. in ein KI-System an den Dienstleister übermittelt werden, also das Institut verlassen. Eingaben sind hier nicht nur Texteingaben („Prompts“), sondern können auch Dokumente oder Mediendateien sein. Dies ist aus Governance- und Datenschutzgründen nicht für alle Daten zulässig. Beispiele hierzu finden sich im Abschnitt „Ausschluss der Nutzung“.

Die Lizenzen der meisten kommerziellen generativen KI-Modelle räumen den Betreibern das Recht ein, die Eingaben der Nutzenden für die eigenen Trainingsdaten, aus denen das eigentliche KI-Modell generiert und verbessert wird, zu verwenden. Dies ist problematisch, da im Extremfall die Eingaben ganz oder teilweise von Dritten wiederhergestellt werden können.

Enthält das Trainingsmaterial urheberrechtlich geschützte Werke, besteht die Gefahr, dass das Ergebnis einer generativen KI den geschützten Werken so nahekommt, dass bei Veröffentlichung eine Rechtsverletzung vorliegen kann. Fast alle Corpora kommerzieller Modelle enthalten solch geschützte Daten, nur wenige freie Modelle verzichten auf urheberrechtlich geschützte Werke und können dies auch garantieren.

Ausschluss der Nutzung

Sensible Geschäftsdaten sowie personenbezogene Daten dürfen nur unter bestimmten Voraussetzungen extern verarbeitet werden. Da derzeit fast alle für WI-Mitarbeitende nutzbaren generativen KI-Dienste in externen Rechenzentren betrieben werden, kommt eine Nutzung in diesen Fällen einer Übermittlung an externe Stellen gleich.

Es ist daher verboten, interne Dokumente des Instituts oder der Verbundpartner des Instituts wie E-Mails, Protokolle oder Berichte in eine generative KI einzuspeisen.

¹ Siehe: Richtlinie zur Nutzung von Diensthandys und privater mobiler Geräte am Weizenbaum-Institut.

Die Eingabe von Informationen über natürliche Personen in generative KI ist verboten, es sei denn, es gibt eine ausdrückliche Rechtsgrundlage und Garantien für die Verarbeitung. Beim Einsatz in Studien ist auf eine spezifische Information der Teilnehmenden zu achten (Einsatz und Zweck von KI-Systemen). Bei Unklarheiten über den Status einer geplanten Verarbeitung ist vor der Durchführung die Datenschutzbeauftragte² zu konsultieren.

Die eingesetzten Produkte und deren Nutzung müssen den ethischen und rechtlichen Standards des Instituts entsprechen.

Verantwortlichkeit

Urheberschaft kann nur von Menschen beansprucht werden. Das bedeutet, dass auch bei einer gekennzeichneten Verwendung der Ergebnisse einer generativen KI die ausführende Person für den Inhalt und auch die Einhaltung der Grundsätze der guten wissenschaftlichen Praxis verantwortlich ist.

Bei der Nutzung von KI im Rahmen von Entscheidungsfindungsprozessen gilt es zwischen automatisierter, ausgelagerter Entscheidungsfindung und der Unterstützung von Entscheidungen zu unterscheiden. Nur die Unterstützung einer Entscheidungsfindung durch generative KI ist zulässig und sorgfältig abzuwägen.

Prinzipien der Nutzung von generativer KI

Vorsicht und Kontrolle

Generative KI kann formal und sprachlich überzeugende Inhalte produzieren, arbeitet aber im Kern nicht logisch-deduktiv, sondern linguistisch-statistisch. Deshalb müssen alle von generativer KI produzierten Inhalte auf Richtigkeit geprüft werden. Dabei ist vor allem auf Erfindungen („Halluzinationen“), inhaltliche Inkonsistenzen sowie Verzerrungen und Vorurteile („bias“) in den ausgegebenen Daten der KI-Systeme zu achten.

Transparenz

Bei wissenschaftlichen Anträgen und Publikationen muss die Verwendung von KI-Systemen transparent gemacht und in Übereinstimmung mit den Vorgaben der Verlage und Zuwendungsgeber erfolgen.

Gültigkeit

Die Richtlinie wurde durch das Direktorium des Weizenbaum-Instituts e. V. verabschiedet am 13.01.2025.

² Kontakt Eva Grübel-Hoffmann: datenschutz@weizenbaum-institut.de

Die Richtlinie wird als lebendiges Dokument regelmäßig überprüft und inhaltlich aktualisiert.

Appendix

Weitere Informationen und Anwendungshinweise finden sich unter: <https://wiki.intern.wei-zenbaum-institut.de/index.php?title=Category:KI>